# SLURM介绍及使用

# 目录

# 整体概况-集群

集群是利用通信网络将一组计算机（节点）按某种结构连接起来，在并行化设计及可视化人机交互集成开发环境支持下，统一调度、协调处理，实现高效并行处理的系统。所有计算机节点一起工作如同一个单一集成的系统资源，实现单一系统映像。

- 包含计算、存储、网络等各种资源实体且彼此联系的资源集合；
- 在物理上，一般由计算处理、互联通信、I/O 存储、操作系统、编译器、运行环境、开发工具等多个软硬件子系统组成；
- 节点是集群的基本组成单位，从角色上一般可以划分为管理节点、登录节点、计算节点、存储节点等。

# 整体概况-集群

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| adios | ferret | grads | hdf5 | ioapi | ncl_ncarg | nlopt | plapack | udunits |
| blas | fftw | grib_api | hdfeos | jasper | nco | openblas | plasma | wgrib |
| boost | geos | gsl | hdfeos5 | lapack | ncview | parallel-netcdf | proj | wgrib2 |
| esfm | GotoBlas2 | hdf | hypre | libpng16 | netcdf | petsc | scalapack | |




# 整体概况-应用领域


计算机辅助工程，广泛应用于结构力学、电磁仿真中
工程仿真
物质的物理化学材料属性的科研工作中
物理化学材料
生命科学
基因科学、蛋白质科学的研究，药物设计等
应用领域
石油勘探
大气环境海洋
地震资料处理，用于油气勘探
遥感
气象、环境、海洋的数值预报
卫星遥感数据分析处理

# 整体概况-集群节点规划

| 角色类型 | 节点范围 | 软件路径 | 运行服务 |
| --- | --- | --- | --- |
| 登录节点 | login01~login10 | 1. 调度软件安装目录/opt/gridview，主要包括munge、slurm两个软件。 | munge.service |
| 管理节点 | admin01（主用）<br>admin02（备用） | 1. 调度软件安装目录/opt/gridview，包括munge、slurm。<br>2. 数据库软件目录/opt/mysql-5.7.25-linux-glibc2.12-x86_64 | munge.service<br>slurmdbd.service<br>slurmctld.service |
| 计算节点 | node1~node666 | 1. 调度软件安装目录/opt/gridview，包括munge、slurm | munge.service<br>slurmd.service |
| MySQL节点 | admin01（主用）<br>admin02（备用） | 1. 数据库软件/opt/mysql-5.7.25-linux-glibc2.12-x86_64 | my_mysqld |

# 目录

# 用户登录及提交作业

## 通过曙光计算云登录

https://ac.sugon.com/

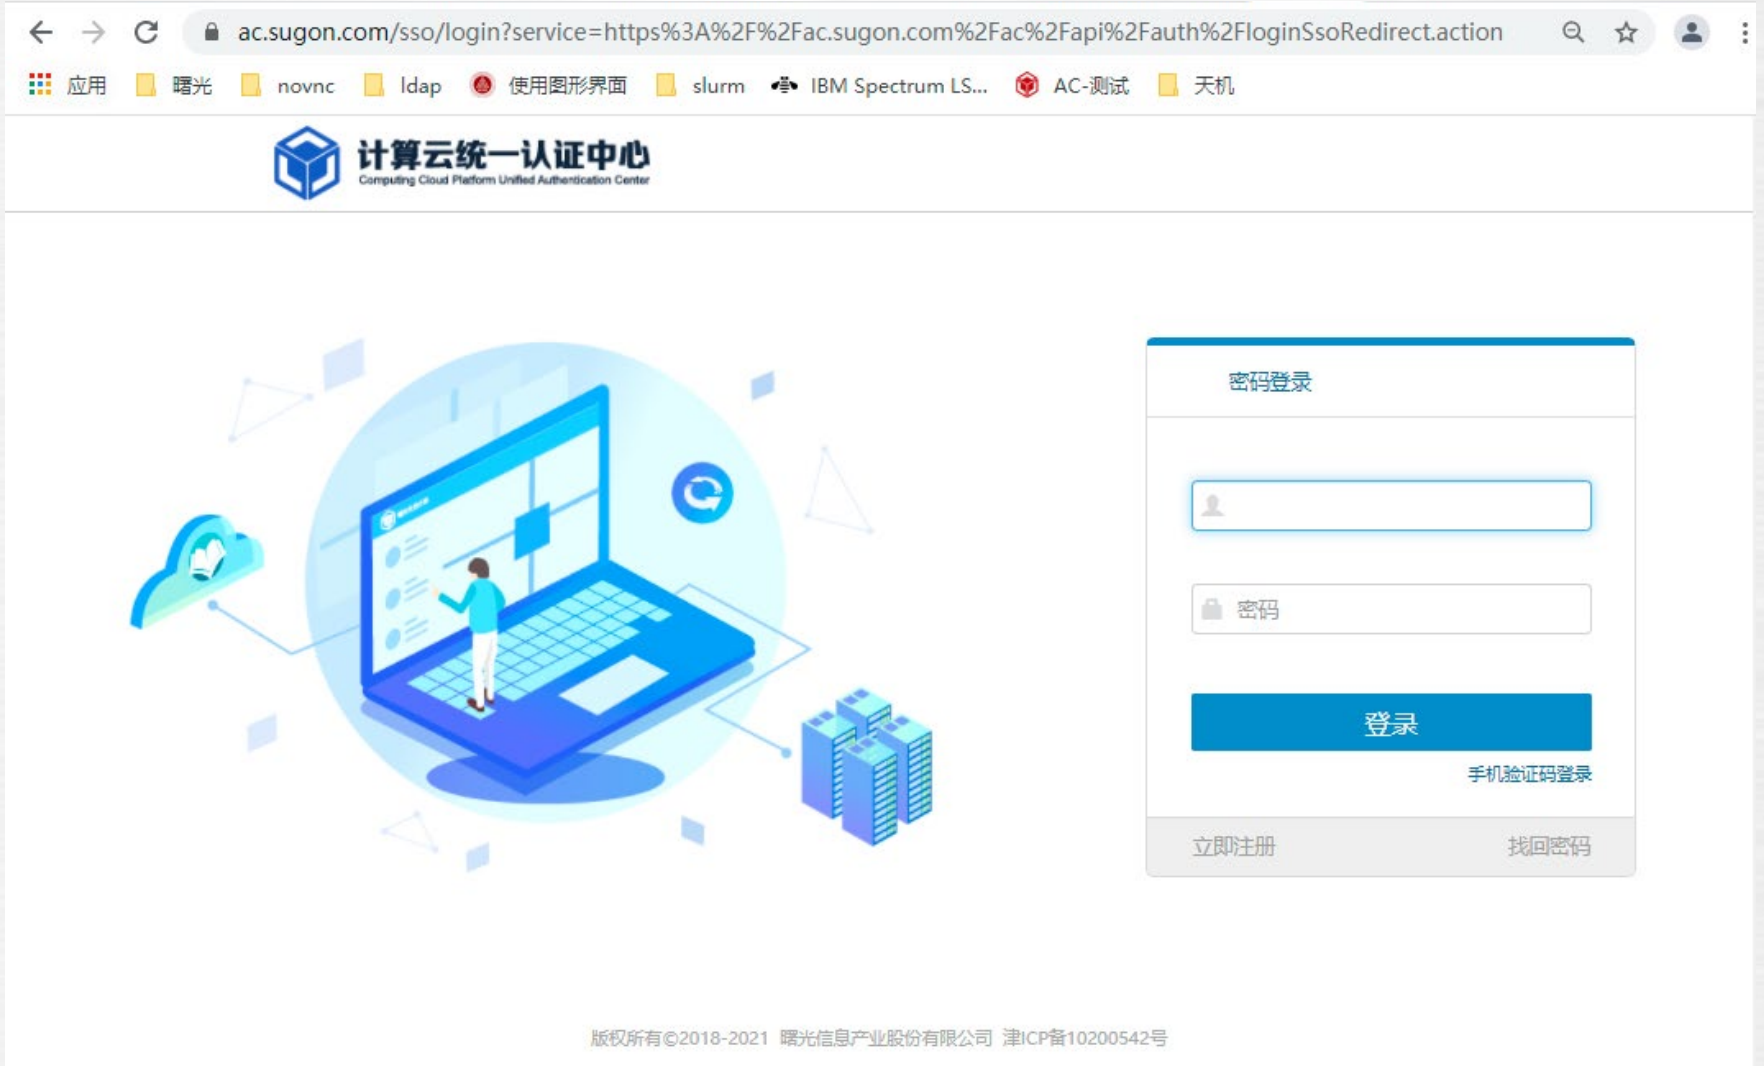

# 用户登录及提交作业

查看用户信息

及可用资源情况

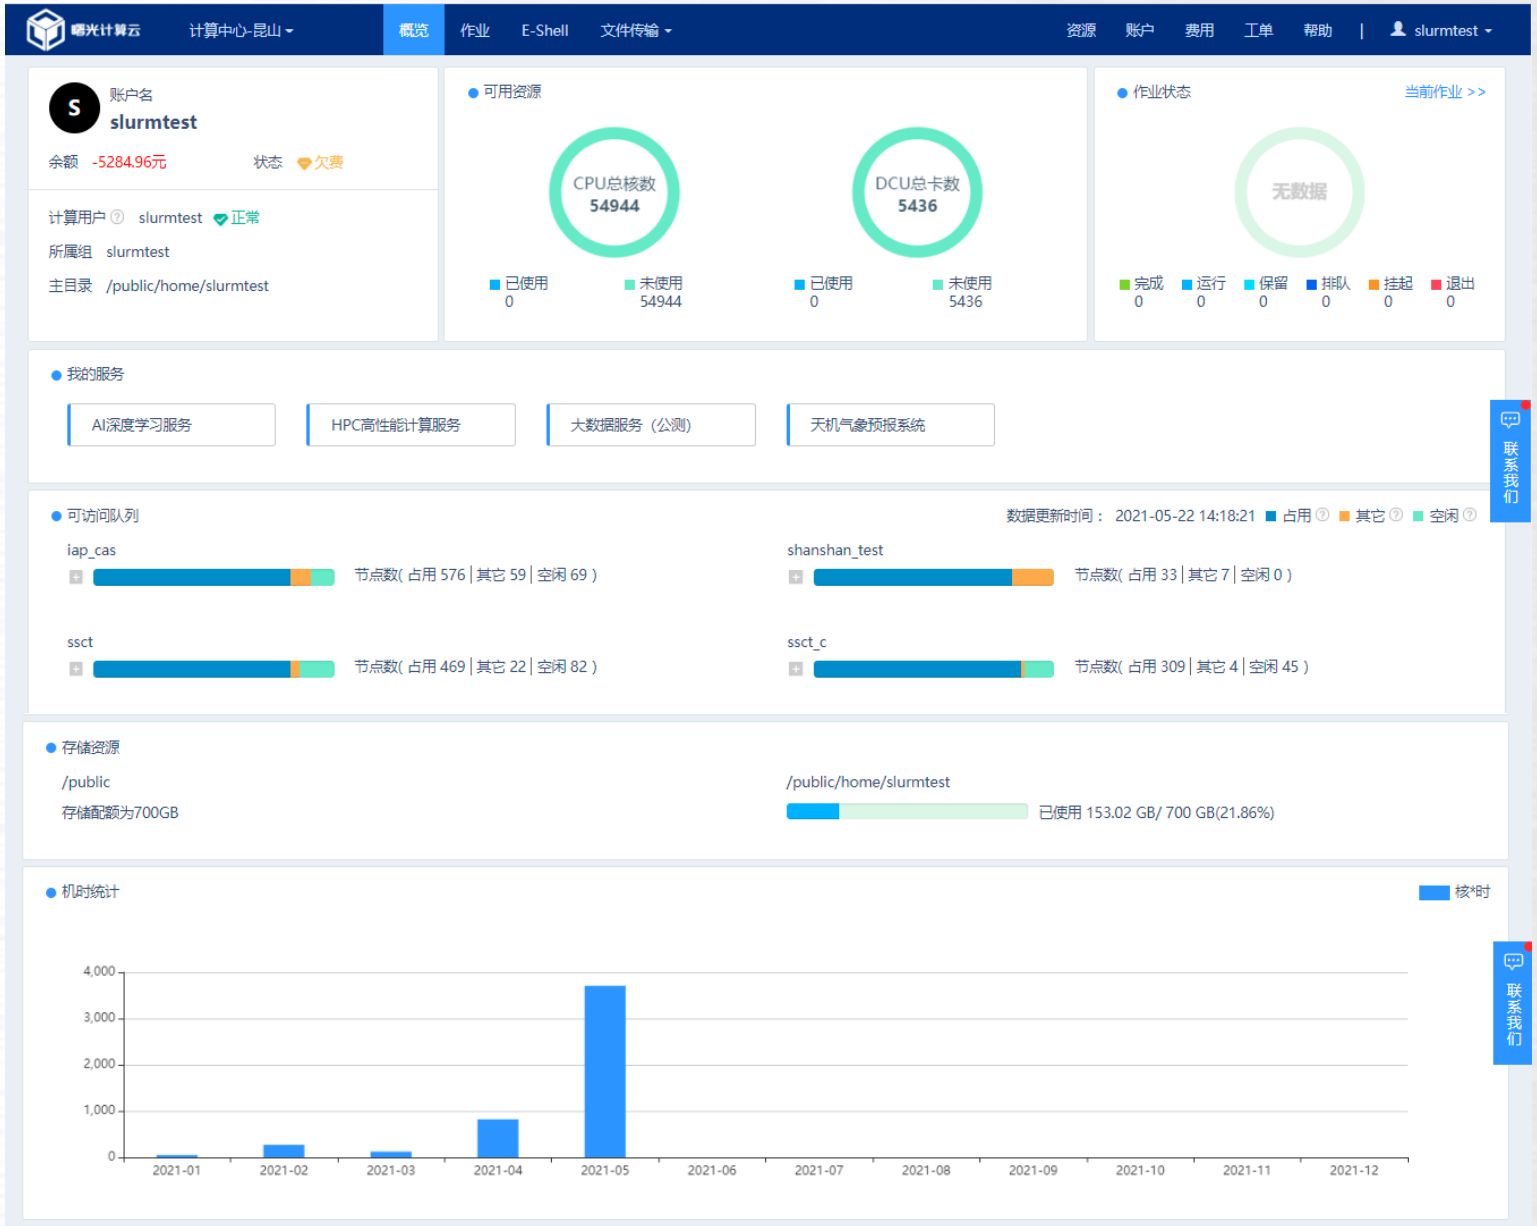

# 用户登录及提交作业

## 文件传输E-File

# 用户登录及提交作业

作业模板：$HOME/slurm_template

计算中心： 计算中心-昆山 计算用户： slurmtest

```
[slurmtest@login03 ~]$ pwd
/public/home/slurmtest
[slurmtest@login03 ~]$ cd slurm_template/
[slurmtest@login03 slurm_template]$ ls
autodyn.slurm  fire_openmpi_slurm  List.txt       sleep.slurm       slurmFdtd.slurm     slurmLammps.slurm   SU2.slurm      test.openmpi
cfx-b.slurm    fireV2.c            logs           slurmAnsys.slurm  slurmFluent.slurm   slurmStarccm.slurm  test.mpi       zhangtao.mpirun
fire.c         FLUENT.slurm        LS-DYNA.slurm  slurmCfx.slurm    slurmGromacs.slurm  slurmVasp.slurm     testmpi.slurm  zhangtao.srun
[slurmtest@login03 slurm_template]$
```

# 用户登录及提交作业

## E-Shell提交作业

计算中心： 计算中心-昆山 计算用户： slurmtest

```
[slurmtest@login03 ~]$ pwd
/public/home/slurmtest
[slurmtest@login03 ~]$ cd slurm_template/
[slurmtest@login03 slurm_template]$ ls
autodyn.slurm  fire_openmpi_slurm  List.txt       sleep.slurm       slurmFdtd.slurm     slurmLammps.slurm   SU2.slurm      test.openmpi
cfx-b.slurm    fireV2.c            logs           slurmAnsys.slurm  slurmFluent.slurm   slurmStarccm.slurm  test.mpi       zhangtao.mpirun
fire.c         FLUENT.slurm        LS-DYNA.slurm  slurmCfx.slurm    slurmGromacs.slurm  slurmVasp.slurm     testmpi.slurm  zhangtao.srun
[slurmtest@login03 slurm_template]$ vim test.mpi
[slurmtest@login03 slurm_template]$ sbatch test.mpi
Submitted batch job 8013571
[slurmtest@login03 slurm_template]$ squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
           8013571     sugon     FIRE slurmtes  R       0:03      1 j09r3n04
[slurmtest@login03 slurm_template]$
```

选中文本复制，点击 这里 或ctrl+shift+v粘贴　　发送组合键： ctrl+w

# 用户登录及提交作业

## 作业查看（当前作业，历史作业，作业详情）

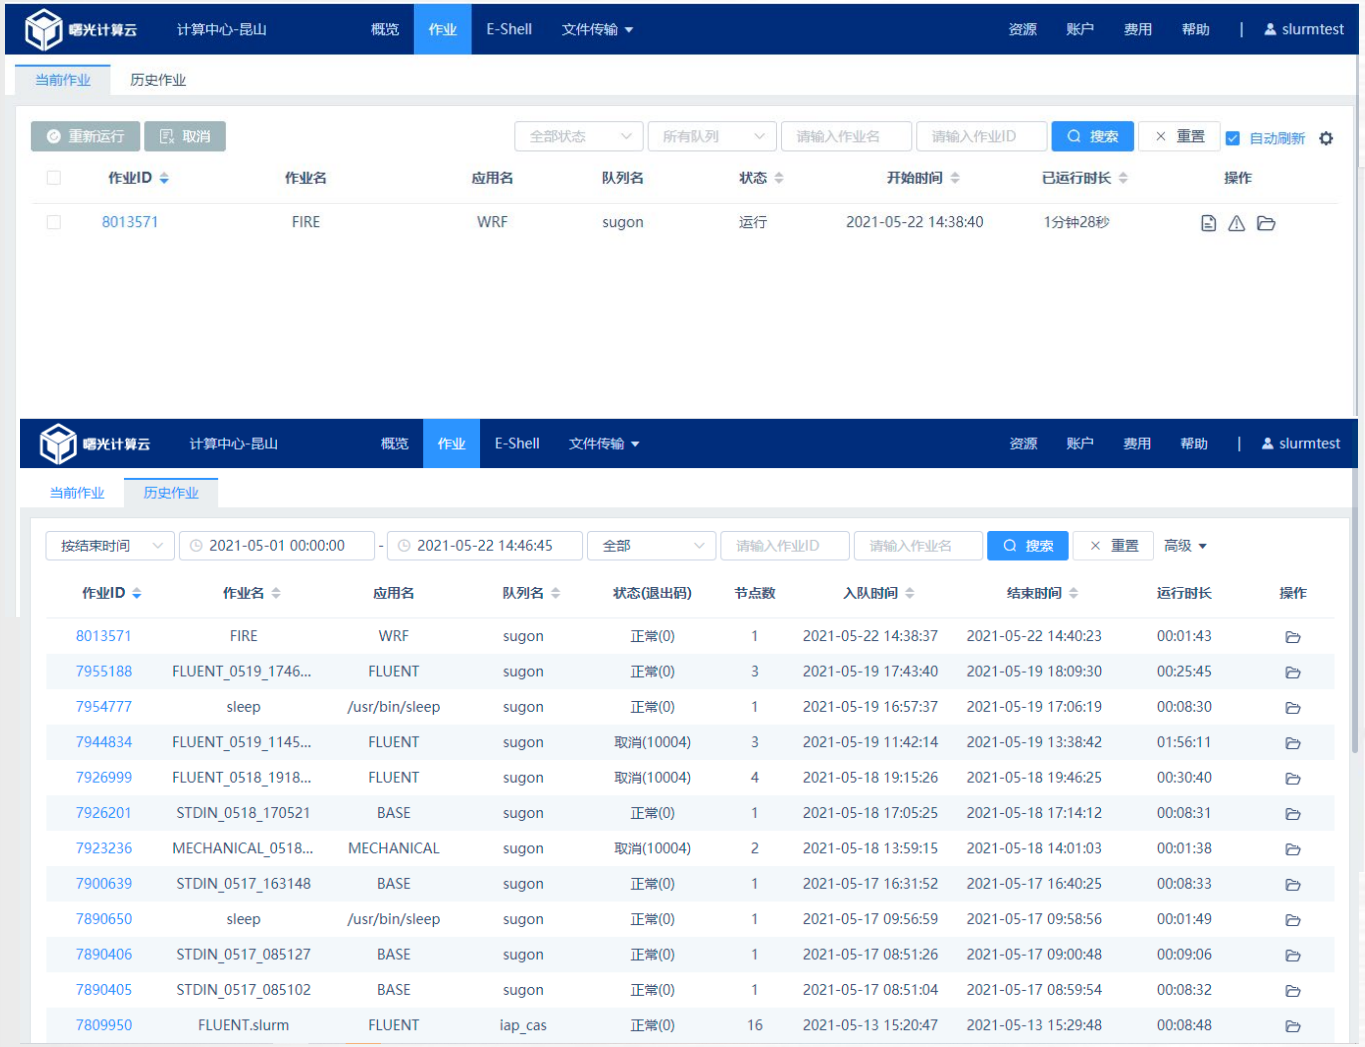


# 目录

# 软件存储目录

## 存储目录及用途

| 目录 | 挂载节点 | 备注 |
| --- | --- | --- |
| /public | 管理节点、<br>登录节点、<br>计算节点 | 用户家目录为/public/home目录。<br>应用软件目录为/public/software目录。 |

# 可用软件

计算系统安装了多种编译环境及应用，主要包括编译器、调试器、mpi并行开发环境及数学库等四部分。

软件安装目录为/public/software。

为方便使用，集群软件环境通过modules工具管理环境变量。

```
[slurmtest@glogin software]$ ls
apps  benchmark  compiler  mathlib  modules  mpi  profile.d
[slurmtest@glogin software]$
```

# 环境变量设置

“Environment module”（环境模块)是一组环境变量设置的集合。module可以被加载(load)、卸载(unload)、切换(switch)，这些操作会改变相应的环境变量设置，从而让用户方便地在不同环境间切换。

```
[root@glogin init]# rpm -qa|grep environment
environment-modules-3.2.10-10.el7.x86_64
[root@glogin init]# cat /usr/share/Modules/init/.modulespath
/public/software/modules
[root@glogin init]#
```

- 查看命令帮助-H
- 查看可用模块avail
- 查看已加载模块list
- 加载模块load
- 卸载模块unload
- 切换模块switch
- 卸载全部模块purge
- 显示模块内容show

# 环境变量设置

- 查看可用模块avail

```
[slurmtest@login01 ~]$ module avail

------------------------------------------------------------ /public/software/modules ------------------------------------------------------------
apps/abinit/8.10.3/hpcx-2.4.1-intel2017                apps/SPECFEM3D/rocm2.9/hpcx-v2.4.1-gcc-7.3.1
apps/amber/2018/hpcx-2.4.1-gcc-7.3.1                   apps/SU2/7.0.1/hpcx-2.4.1-gcc-7.3.1
apps/anaconda2/4.3.0                                   apps/TensorFlow/1.14.0/hpcx-2.4.1-gcc-7.3.1
apps/anaconda3/4.9.2                                   apps/TensorFlow/1.14.0-hierarchical/hpcx-2.4.1-gcc-7.3.1
apps/anaconda3/5.2.0                                   apps/TensorFlow/2.2.0/hpcx-2.4.1-gcc-7.3.1
apps/AutoDock-DCU/4.2.6/gcc-7.3.1                      apps/Trimmomatic/0.3.8
apps/automake/1.16.1                                   apps/vasp/5.2.2/intel2017
apps/barracuda-DCU/0.6.2_beta/hpcx-2.4.1-gcc-7.3.1     apps/vasp/5.4.4/hpcx-2.4.1-intel2017
apps/bedtools/2.29.1/gcc-7.3.1                         apps/vaspkit/1.2.4/vaspkit1.2.4
apps/bigDFT/1.8.3/hpcx-2.4.1-intel2017                 apps/vtst/5.4.4/hpcx-2.4.1-intel2017
apps/blast/2.10.0                                      apps/WRF/3.8/hpcx-2.4.1-intel2017
apps/blastn-DCU/2.2.28/gcc-7.3.1                       apps/WRF/4.2/hpcx-2.4.1-intel2017
apps/blastp-DCU/2.2.28/gcc-7.3.1                       compiler/cmake/3.15.6
apps/boost/intel/1.67.0                                compiler/cuda/10.2
apps/bwa/0.7.17/gcc-7.3.1                              compiler/rocm/3.3
apps/Calculix/2.16/hpcx-2.4.1-gcc-7.3.1                compiler/rocm/3.5
apps/canu/1.8/gcc-7.3.1                                compiler/rocm/3.9
apps/CMAQ/5.3/hpcx-2.4.1-intel2017                     compiler/rocm/3.9.1
apps/Code_Aster/13.8/hpcx-2.4.1-gcc-7.3.1              compiler/rocm/4.1.0
apps/cp2k/6.1.0/hpcx-2.4.1-intel2017                   compiler/rocm/socprof
apps/DUNE/2.8/hpcx-2.4.1-gcc-7.3.1                     mathlib/antlr/2.7.7/intel
apps/Elmer/8.4/hpcx-2.4.1-intel2017                    mathlib/cdo/1.7.2/intel
apps/FastQC/0.11.9                                     mathlib/fftw/3.3.8/double/gnu
apps/FlameGraph/master                                 mathlib/fftw/3.3.8/double/intel
```

# 环境变量设置

- 查看已加载模块list
- 查看模块配置show

```
[slurmtest@login01 ~]$ module list
Currently Loaded Modulefiles:
  1) compiler/devtoolset/7.3.1   2) compiler/rocm/2.9          3) mpi/hpcx/2.4.1/gcc-7.3.1
[slurmtest@login01 ~]$ which gcc
/opt/rh/devtoolset-7/root/usr/bin/gcc
[slurmtest@login01 ~]$ which mpirun
/opt/hpc/software/mpi/hpcx/v2.4.1/gcc-7.3.1/bin/mpirun
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ module show compiler/devtoolset/7.3.1
-------------------------------------------------------------------
/opt/hpc/software/modules/compiler/devtoolset/7.3.1:

module-whatis    Name: Developer Toolset
module-whatis    Version: 7.3.1
module-whatis    Category: compiler, runtime support
prepend-path     PATH /opt/rh/devtoolset-7/root/usr/bin
prepend-path     MANPATH /opt/rh/devtoolset-7/root/usr/share/man
prepend-path     INFOPATH /opt/rh/devtoolset-7/root/usr/share/info
prepend-path     PERL5LIB /opt/rh/devtoolset-7/root/usr/lib64/perl5/vendor_perl:/opt/rh/devtoolset-7/root/usr/share/perl5/vendor_perl
prepend-path     LD_LIBRARY_PATH /opt/rh/devtoolset-7/root/usr/lib64:/opt/rh/devtoolset-7/root/usr/lib
prepend-path     C_INCLUDE_PATH /opt/rh/devtoolset-7/root/usr/include/c++/7:/opt/rh/devtoolset-7/root/usr/include/c++/7/x86_64-redhat-linux
prepend-path     CPLUS_INCLUDE_PATH /opt/rh/devtoolset-7/root/usr/include/c++/7:/opt/rh/devtoolset-7/root/usr/include/c++/7/x86_64-redhat-linux
setenv           LDFLAGS -Wl,-rpath=/opt/rh/devtoolset-7/root/usr/lib64 -Wl,-rpath=/opt/rh/devtoolset-7/root/usr/lib
-------------------------------------------------------------------
```

# 环境变量设置

- 加载新模块load
- 卸载模块unload

```
[slurmtest@login01 ~]$ module list
Currently Loaded Modulefiles:
  1) compiler/devtoolset/7.3.1   2) compiler/rocm/2.9          3) mpi/hpcx/2.4.1/gcc-7.3.1
[slurmtest@login01 ~]$ module load compiler/intel/2017.5.239
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ which icc
/opt/hpc/software/compiler/intel/intel-compiler-2017.5.239/bin/intel64/icc
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ module unload compiler/intel/2017.5.239
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ which icc
/usr/bin/which: no icc in (/opt/hpc/software/mpi/hpcx/v2.4.1/gcc-7.3.1/bin:/opt/hpc/software/mpi/hpcx/v2.4.1/hcoll/b
in:/opt/hpc/software/mpi/hpcx/v2.4.1/ucx_without_rocm/bin:/opt/rocm/bin:/opt/rocm/hcc/bin:/opt/rocm/hip/bin:/opt/rh/
devtoolset-7/root/usr/bin:/usr/lib64/qt-3.3/bin:/opt/hpc/software/mpi/pmix/bin:/opt/hpc/software/mpi/pmix/sbin:/opt/
hpc/software/mpi/hpcx/v2.4.1/ucx_without_rocm//bin:/opt/hpc/software/mpi/hpcx/v2.4.1/ucx_without_rocm//sbin:/public/
home/slurmtest/perl5/bin:/opt/gridview/slurm/bin:/opt/gridview/slurm/sbin:/opt/gridview/munge/bin:/opt/gridview/mung
e/sbin:/opt/clusconf/sbin:/opt/clusconf/bin:/usr/local/bin:/usr/bin:/usr/local/sbin:/usr/sbin:/opt/ibutils/bin:/publ
ic/home/slurmtest/.local/bin:/public/home/slurmtest/bin)
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$
```

# 环境变量设置

- 置换模块switch
- 清理已加载模块purge

```
[slurmtest@login01 ~]$ module list
Currently Loaded Modulefiles:
  1) compiler/devtoolset/7.3.1   2) compiler/rocm/2.9          3) mpi/hpcx/2.4.1/gcc-7.3.1
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ which gcc
/opt/rh/devtoolset-7/root/usr/bin/gcc
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ which icc
/usr/bin/which: no icc in (/opt/hpc/software/mpi/hpcx/v2.4.1/gcc-7.3.1/bin:/opt/hpc/software/mpi/hpcx/v2.4.1/hcoll/bin:/opt/hpc/software/mpi/
4.1/ucx_without_rocm/bin:/opt/rocm/bin:/opt/rocm/hcc/bin:/opt/rocm/hip/bin:/opt/rh/devtoolset-7/root/usr/bin:/usr/lib64/qt-3.3/bin:/opt/hpc/s
mpi/pmix/bin:/opt/hpc/software/mpi/pmix/sbin:/opt/hpc/software/mpi/hpcx/v2.4.1/ucx_without_rocm//bin:/opt/hpc/software/mpi/hpcx/v2.4.1/ucx_wi
cm//sbin:/public/home/slurmtest/perl5/bin:/opt/gridview/slurm/bin:/opt/gridview/slurm/sbin:/opt/gridview/munge/bin:/opt/gridview/munge/sbin:/
conf/sbin:/opt/clusconf/bin:/usr/local/bin:/usr/bin:/usr/local/sbin:/usr/sbin:/opt/ibutils/bin:/public/home/slurmtest/.local/bin:/public/home
st/bin)
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ module switch compiler/devtoolset/7.3.1 compiler/intel/2017.5.239
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ which gcc
/usr/bin/gcc
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ which mpirun
/opt/hpc/software/mpi/hpcx/v2.4.1/gcc-7.3.1/bin/mpirun
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ module list
Currently Loaded Modulefiles:
  1) compiler/intel/2017.5.239   2) compiler/rocm/2.9          3) mpi/hpcx/2.4.1/gcc-7.3.1
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ module purge
[slurmtest@login01 ~]$
[slurmtest@login01 ~]$ module list
No Modulefiles Currently Loaded.
```

默认加载的3个模块

切换模块，加载intel编译器，卸载gcc7.3.1

list查看切换结果

清空所有加载模块

# 环境变量设置

module 命令可以直接写在.bashrc中

```
[slurmtest@login01 ~]$ cat .bashrc
# .bashrc

# Source global definitions
if [ -f /etc/bashrc ]; then
        . /etc/bashrc
fi

# Uncomment the following line if you don't like systemctl's auto-paging feature:
# export SYSTEMD_PAGER=

# User specific aliases and functions
export OMPI_TIMING_ENABLE=1
export SLURM_PMIX_DIRECT_CONN=true
export SLURM_PMIX_DIRECT_CONN_UCX=false
export SLURM_PMIX_DIRECT_CONN_EARLY=true
#export SLURM_PMIX_FENCE=tree
export UCX_TLS=dc

#module purge
#module load  compiler/rocm/2.9
#module load  compiler/intel/2017.5.239
#module load  mpi/hpcx/2.4.1/intel-2017.5.239

[slurmtest@login01 ~]$
```

自定义用户默认环境

# 目录

# 调度系统-基本概念

**作业**

- ✓ 物理构成，一组关联的资源分配请求，以及一组关联的处理过程；
- ✓ 交互方式，可以分为交互式作业和非交互式作业；

**队列**

- ✓ 组织资源的一种形式
- ✓ 带名称的作业容器、用户访问控制、资源使用限制；

**调度系统**

- ✓ 负责监控和管理集群中资源和作业的软件系统；
- ✓ 通常由资源管理器、调度器、任务执行器，以及用户命令和API组成；

**集群**

- ✓ 包含计算、存储、网络、操作系统、编译器、运行环境、开发工具等各种资源实体且彼此联系的资源集合；

**资源**

- ✓ 作业运行过程中使用的可量化实体都是资源；
- ✓ 硬件资源（节点、内存、CPU 、类GPU加速卡等）和软件资源（如License）；

# 调度系统-主要作用

多任务管理

系统资源整合

单一系统镜像

资源访问控制

**集群操作系统**

# 调度系统-SLURM主要特点

## 架构设计优秀

- 扩展性（功能/规模）
- 高性能（提交/调度）
- 灵活性（自定义插件）
- 容错性（服务/节点/作业）

## 特色功能突出

- 资源绑定（CPU、MEM、类GPU加速卡等各类资源）
- 关联调度（如类GPU加速卡关联CPU）
- 能耗管理（限频、开关机、记账等）
- 拓扑调度（基于拓扑结构调度，限定交换机数等）

## 基础功能完善

- 优先级策略（Multi-Factor）
- 作业调度（FairShare/Backfill/ FCFS, etc）
- 资源竞争（Exclusive/Preempt/Gang, etc）
- 多级限制（Cluster/Account/User/Partition, etc）
- 资源预留（CPU/MEM/类GPU加速卡/License, etc）

## 兼容性/交互性良好

- MPI兼容（IntelMPI/MVAPICH/OpenMPI,etc）
- LSF兼容（bsub/bjobs/bqueue/bhosts, etc）
- PBS兼容（qsub/qstat/pbsnodes/pestat, etc）
- 分析工具（融合Influxdb/ES/HDF5等，方便分析）

# 作业管理-查看分区sinfo

| sinfo命令参数（1/2） | |
|---|---|
| **-p <partition>, --partition=<partition>** | 查看指定分区的状态，对应环境变量SINFO_PARTITION。<br>示例：sinfo -p caspra |
| **-n <nodes>, --nodes=<nodes>** | 查看指定节点的信息。<br>示例：sinfo -p caspra -n e02r4n[00-19] |
| **-N, --Node** | 以面向节点（默认为分区）的格式打印信息，每行一个节点。<br>示例：sinfo -N -p caspra -n e02r4n[00-19] |
| **-t <states> ,<br>--states=<states>** | 查询指定节点状态的分区或节点的信息。<br>常见状态包括：alloc idle drain down drng。 |
| **-s, --summarize** | 查看分区中节点状态的摘要信息。<br>主要是限制分区中节点的状态统计，如已分配数alloc、空闲数idle、总数total等。 |

# 作业管理-查看分区sinfo

| sinfo参数介绍（2/2） | |
|---|---|
| -o <output_format>,<br>--format=<br><output_format> | 按照指定的格式显示信息，对应变量SINFO_FORMAT。<br>格式为“%[[.]size]<type> %[[.]size]<type> …”。<br>其中，点号（.）表示右对齐，size表示字段长度，type为代表特定字段的字符（或字符串）。示例如下：<br>sinfo -o %all 以数显分隔的形式显示所有字段。<br>sinfo -o "%9P %.5a %.10l %.6D %.6t %N"<br>显示内容：分区名-分区状态 -最大运行时间-节点数-节点状态-节点列表。 |
| -O <output_format>,<br>--Format=<br><output_format> | 按照指定的字段显示状态信息。<br>格式为“type[:[.]size],type[:[.]size],…”。<br>其中，type为代表特定字段的字段名，点号（.）表示右对齐，size表示字段长度。示例如下：<br>sinfo -O all<br>sinfo -O Partition:9,available:.6,time:.11,nodes:.6,statecompact:.6,nodelist:.12 |

# 作业管理-查看分区

示例2: 查看分区的摘要信息（--summarize）。

等价于 sinfo -o "%9P %.5a %.10l %.16F  %N"

```
[slurmtest@glogin ~]$ sinfo --summarize
PARTITION AVAIL  TIMELIMIT   NODES(A/I/O/T)  NODELIST
debug        up   infinite          1/3/0/4  node[1001-1004]
fat1t        up 3-00:00:00        1/11/4/16  node[1001-1016]
fat3t        up 3-00:00:00          0/6/0/6  node[1021-1026]
v100         up 3-00:00:00        10/2/0/12  node[1031-1042]
hcpu         up 3-00:00:00      1/250/1/252  node[2001-2252]
gpu          up 3-00:00:00        0/36/1/37  node[151-173,175-182,184-186,188-190]
gpu4         up 3-00:00:00        0/31/0/31  node[201-211,213,215-220,222-224,226-230,232-236]
```

示例3: 查看分区详情。

scontrol show partition

```
[slurmtest@glogin ~]$ scontrol show partition debug
PartitionName=debug
   AllowGroups=ALL AllowAccounts=bujd,haowj,jiangzhilin,liyuan,root,sugon,test02,wangrongpt0224,liurx,wangrongpt02241,zoubs,lyuzh,im_ysd,panzhang
,sunpeng,aiss,liurx01,houfy,sgzhou,tianlh,zhouhj,zhousen,guozk,yangg,chenxs,wangyt,jshu,ybyang,wangshancai,yuliangjin,anna_itp,cairg,xianzy,oyzc,
huangqg,wenghongming,ktitimbo AllowQos=ALL
   AllocNodes=ALL Default=NO QoS=N/A
   DefaultTime=02:00:00 DisableRootJobs=NO ExclusiveUser=NO GraceTime=0 Hidden=NO
   MaxNodes=UNLIMITED MaxTime=UNLIMITED MinNodes=0 LLN=YES MaxCPUsPerNode=UNLIMITED
   Nodes=node[1001-1004]
   PriorityJobFactor=1 PriorityTier=6000 RootOnly=NO ReqResv=NO OverSubscribe=NO
   OverTimeLimit=NONE PreemptMode=OFF
   State=UP TotalCPUs=224 TotalNodes=4 SelectTypeParameters=NONE
   JobDefaults=(null)
   DefMemPerNode=UNLIMITED MaxMemPerNode=UNLIMITED
```

# 作业管理-查看节点

**节点详情：** scontrol show node node151

```
[slurmtest@glogin ~]$ scontrol show node node151
NodeName=node151 Arch=x86_64 CoresPerSocket=6
   CPUAlloc=0 CPUTot=12 CPULoad=0.01
   AvailableFeatures=(null)
   ActiveFeatures=(null)
   Gres=gpu:TeslaK20m:2
   NodeAddr=node151 NodeHostName=node151 Version=19.05.5
   OS=Linux 3.10.0-957.el7.x86_64 #1 SMP Thu Nov 8 23:39:32 UTC 2018
   RealMemory=31983 AllocMem=0 FreeMem=16966 Sockets=2 Boards=1
   State=IDLE ThreadsPerCore=1 TmpDisk=0 Weight=1 Owner=N/A MCS_label=N/A
   Partitions=gpu
   BootTime=2020-05-21T14:57:56 SlurmdStartTime=2020-07-06T16:11:06
   CfgTRES=cpu=12,mem=31983M,billing=12,gres/gpu=2
   AllocTRES=
   CapWatts=n/a
   CurrentWatts=0 AveWatts=0
   ExtSensorsJoules=n/s ExtSensorsWatts=0 ExtSensorsTemp=n/s
```

# 作业管理-作业提交

| srun | sbatch | salloc |
| --- | --- | --- |
| 交互式作业提交 | 批处理作业提交 | 节点资源获取 |

# 作业管理-作业提交参数

| 选项 | 含义 | 类型 | 示例 |
| --- | --- | --- | --- |
| -J | 作业名称，使用squeue看到的作业名 | 字符串 | -J wrf；表示作业名称为“wrf” |
| -n | 作业申请的总cpu核心数 | 数值 | -n 240；表示作业申请240个cpu核心 |
| -N | 作业申请的节点数 | 数值 | -N 10 表示作业申请10个计算节点 |
| -p | 指定作业提交的队列 | 字符串 | -psilicon表示将作业提交到silicon队列 |
| --ntasks-per-node | **指定每个节点运行进程数** | **数值** | **--ntasks-per-node=32表示每个节点运行32个进程（任务）** |
| --ntasks-per-socket=<count> | **指定在每个Socket启动的进程数** | **数值** | **--ntasks-per-node=2标识每个Socket上运行2个进程** |
| --cpus-per-task=<count> | **指定任务需要的处理器数目** | **数值** | **--cpus-per-task=8 表示每个任务占用8个处理器核** |
| -t | 指定作业的执行时间，若超过该时间，作业将会被杀死 | 数值 | -t 30 表示作业的执行时间不超过30分钟，格式可以为：时:分:秒 |
| -w, --nodelist=hosts... | 指定分配特定的计算节点 | 字符串 | -w t0100,t0101 表示使用t0100 t0101等2个节点 |
| --mem=<size[units]> | 指定作业在每个节点使用的内存限制。 | 数字 | --mem=2G<br>限定作业在每个节点最多占用2G的最大内存。 |
| -d, --dependency=<dependency_list> | 作业依赖关系设置 | 字符串 | -d after:123 表示本作业须待作业123开始以后再执行 |
| --gres=<list> | 指定每个节点使用通用资源名称及数量 | 字符串 | --gres=gpu:2 表示本作业使用gpu卡，且每个节点使用2卡 |

# 作业提交-sbatch

[sugon@gpunode1 ~]$ **sbatch -n 4 sleep.job** **//**sbatch 只接收脚本
Submitted batch job 19

[sugon@gpunode1 ~]$ cat sleep.job //脚本格式示例
#!/bin/bash
#SBATCH -J sleep //指定作业名
#SBATCH -p debug //指定队列
#SBATCH --time=00:01:00 //指定运行时间（分钟）注：需要设定为比较准确的时间，否则调度系统会超时强杀作业。若不设置该参数，继承队列的默认运行时长。请在程序中设置断点，保存中间结果，防止程序中断或者异常导致中间结果丢失。
#SBATCH -N 2 //请求节点数
#SBATCH -n 2 //请求核心数
#SBATCH --gres=gpu:2 //请求gpu数
#SBATCH -o logs/%j.sleep //标准输出文件 注：若为相对路径，则必须存在该目录，否则作业会提交失败，且无日志输出
#SBATCH -e logs/%j.sleep //错误输出文件 注：若为相对路径，则必须存在该目录，否则作业会提交失败，且无日志输出
echo ${SLURM_JOB_NODELIST} 作业占用节点列表
echo start on $(date) 开始时间
sleep 100 执行命令
echo end on $(date) 结束时间

# 作业提交-srun

例：提交请求2个节点2个核心的并且指定作业的名称为job1

```
srun –J  job1 –N 2 –n 2 sleep 10
```

# 作业管理-作业查看

## squeue:查询排队和运行状态的作业

| 参数 | 解释 |
| --- | --- |
| -A, --account=account(s) | 查询指定账号的作业，默认全部账号下的作业 |
| -j, --jobs <job_id_list> | 查看指定JOB IDS的作业信息，默认显示全部 |
| -n, --name=<name> | 查看指定名称的作业信息 |
| -p, --partition=<names> | 查看指定分区的作业信息 |
| --state=<names> | 指定状态查看作业信息 |
| --users=<names> | 指定用户名称查看作业信息 |

```
[slurmtest@glogin slurm_template]$ squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
             43248      hcpu     test slurmtes  R       0:01     10 node[2005-2014]
             43247     debug      OMP slurmtes  R       0:05      2 node[1001,1003]
[slurmtest@glogin slurm_template]$
```

# 作业管理-作业查看

查询指定作业详情:
scontrol show job [-d] [<jobid>]

```
[slurmtest@login05 newtest]$ scontrol show jobs -d 1434869
JobId=1434869 JobName=DTCP
   UserId=slurmtest(1232) GroupId=slurmtest(1225) MCS_label=N/A
   Priority=1084 Nice=0 Account=slurmtest QOS=normal
   JobState=COMPLETED Reason=None Dependency=(null)
   Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
   DerivedExitCode=0:0
   RunTime=00:00:21 TimeLimit=00:20:00 TimeMin=N/A
   SubmitTime=2020-03-29T17:55:18 EligibleTime=2020-03-29T17:55:18
   AccrueTime=2020-03-29T17:55:18
   StartTime=2020-03-29T17:55:18 EndTime=2020-03-29T17:55:39 Deadline=N/A
   SuspendTime=None SecsPreSuspend=0 LastSchedEval=2020-03-29T17:55:18
   Partition=caspra AllocNode:Sid=login05:126240
   ReqNodeList=e02r4n[18-19] ExcNodeList=(null)
   NodeList=e02r4n[18-19]
   BatchHost=e02r4n18
   NumNodes=2 NumCPUs=16 NumTasks=16 CPUs/Task=1 ReqB:S:C:T=0:0:*:*
   TRES=cpu=16,mem=45600M,node=2,billing=16,gres/dcu=8
   Socks/Node=* NtasksPerN:B:S:C=8:0:2:* CoreSpec=*
     Nodes=e02r4n[18-19] CPU_IDs=0-1,8-9,16-17,24-25 Mem=22800 GRES=
   MinCPUsNode=8 MinMemoryCPU=2850M MinTmpDiskNode=0
   Features=(null) DelayBoot=00:00:00
   OverSubscribe=OK Contiguous=0 Licenses=(null) Network=(null)
   Command=/public/home/slurmtest/zhangtao/cpubind/newtest/sgsrun.slurm
   WorkDir=/public/home/slurmtest/zhangtao/cpubind/newtest
   StdErr=/public/home/slurmtest/zhangtao/cpubind/newtest/1434869
   StdIn=/dev/null
   StdOut=/public/home/slurmtest/zhangtao/cpubind/newtest/1434869
   Power=
   TresPerNode=dcu:4

[slurmtest@login05 newtest]$
```

作业资源分布

# 作业管理-作业删除

## scancel：删除作业命令

| COMMAND | 解释 |
| --- | --- |
| scancel <jobid> | 删除指定作业 |
| scancel -t ST | 删除指定状态的作业 |
| scancel --account=<name> | 删除指定账号的作业 |
| scancel --name=<name> | 删除指定名称的作业 |
| scancel --partition=<names> | 删除指定分区的作业 |
| scancel --reservation=<name> | 删除指定预约名称的作业 |
| scancel --state=<names> | 删除指定状态的作业 |
| scancel --user=<name> | 删除指定用户的作业 |
| scancel --nodelist=<names> | 删除指定节点的作业 |

# 作业控制 - scontrol

## scontrol：控制作业命令

| COMMAND | 解释 | 备注 |
| --- | --- | --- |
| scontrol suspend <jobid> | 挂起作业 | 运行作业可挂起 |
| scontrol resume <jobid> | 恢复作业 | 挂起作业可恢复 |
| scontrol requeue <jobid> | 作业重新排队 | 运行作业可重新排队 |
| scontrol hold <id/name> | 保留作业 | 排队作业可保留 |
| scontrol release <id/name> | 释放作业 | 保留作业可释放 |

# 目录

# 进程绑定：SLURM绑定参数

绑定资源
CPU MEM 类GPU加速卡

常用参数：

- --ntasks-per-<node|socket|core..>
- --mem/--mem-per-cpu
- --cpu-bind=<socket|core|ldoms|verbose…>

https://slurm.schedmd.com/mc_support.html

| | |
|---|---|
| **Low-level (explicit binding)** | |
| --cpu-bind=... | Explicit process affinity binding and control options |
| **High-level (automatic mask generation)** | |
| --sockets-per-node=*S* | Number of sockets in a node to dedicate to a job (minimum) |
| --cores-per-socket=*C* | Number of cores in a socket to dedicate to a job (minimum) |
| --threads-per-core=*T* | Number of threads in a core to dedicate to a job (minimum) |
| -B *S[:C[:T]]* | Combined shortcut option for --sockets-per-node, --cores-per_cpu, --threads-per_core |
| **Task Distribution Options** | |
| -m / --distribution | Distributions of: arbitrary \| block \| cyclic \| plane=*x* \| [block\|cyclic]:[block\|cyclic\|fcyclic] |
| **Memory as a consumable resource** | |
| --mem=*mem* | amount of real memory per node required by the job. |
| --mem-per-cpu=*mem* | amount of real memory per allocated CPU required by the job. |
| **Task invocation control** | |
| --cpus-per-task=*CPUs* | number of CPUs required per task |
| --ntasks-per-node=*ntasks* | number of tasks to invoke on each node |
| --ntasks-per-socket=*ntasks* | number of tasks to invoke on each socket |
| --ntasks-per-core=*ntasks* | number of tasks to invoke on each core |
| --overcommit | Permit more than one task per CPU |
| **Application hints** | |
| --hint=compute_bound | use all cores in each socket |
| --hint=memory_bound | use only one core in each socket |
| --hint=[no]multithread | [don't] use extra threads with in-core multi-threading |
| **Resources reserved for system use** | |
| --core-spec=*cores* | Count of cores to reserve for system use |
| --thread-spec=*threads* | Count of threads to reserve for system use (future) |

# 作业脚本示例1—串行作业示例

串行作业的提交示例：

```
#!/bin/bash
#SBATCH -o log/%j
#SBATCH -J SERIAL
#SBATCH -p debug
#SBATCH -t 00:10:00
#SBATCH --mem-per-cpu=3G
#SBATCH -n 1
#SBATCH -w e16r1n00
#SBATCH --tasks-per-node=1

module load compiler/devtoolset/7.3.1
module load compiler/rocm/2.9
module load mpi/hpcx/2.4.1/gcc-7.3.1

#  4x32, about   60 sec
export LOOPMAX=1000000

time srun --mpi=pmix_v3 ./open_fire_v5 $LOOPMAX
# 或者直接运行
#time  ./open_fire_v5 $LOOPMAX
```

提交串行作业时，在脚本中直接调用可执行程序

# 作业脚本示例2—MPI作业

简化的MPI作业的提交示例：

```
#SBATCH -o log/%j
#SBATCH -J MPI
#SBATCH -p debug
#SBATCH -t 00:10:00
#SBATCH --mem-per-cpu=3G
#SBATCH -N 20
#SBATCH --tasks-per-node=32

module load compiler/devtoolset/7.3.1
module load compiler/rocm/2.9
module load mpi/hpcx/2.4.1/gcc-7.3.1

echo "============================="
env | grep "SLURM"
echo "============================="

ulimit -a
which mpirun

# 20x32, 60 sec
export LOOPMAX=5000000

echo "use srun, loop=$LOOPMAX" && time srun --mpi=pmix_v3 ./open_fire_v5 $LOOPMAX
```

# 作业脚本示例3—单节点OpenMP作业

简化的OpenMP作业脚本示例：

```
#!/bin/bash
#SBATCH -J OPENMP
#SBATCH -p debug
#SBATCH -N 1
#SBATCH -n 4
#SBATCH --cpus-per-task=2
#SBATCH -o log/%j.loop

module load compiler/devtoolset/7.3.1
module load compiler/rocm/2.9
module load mpi/hpcx/2.4.1/gcc-7.3.1

export OMP_NUM_THREADS=2
srun ./calc_openmp_init
```

设置变量OMP_NUM_THREADS，控制单进程的并发线程数

# 作业脚本示例4—MPI+OpenMP

简化的MPI+OpenMP作业脚本示例：

```
#!/bin/bash
#SBATCH -J OPENMP
#SBATCH -p debug
#SBATCH -N 2
#SBATCH -n 8
#SBATCH --ntasks-per-node=4
#SBATCH --cpus-per-task=8

module load compiler/devtoolset/7.3.1
module load compiler/rocm/2.9
module load mpi/hpcx/2.4.1/gcc-7.3.1

export OMP_NUM_THREADS=8
srun --mpi=pmix_v3 ./calc_openmp_mpi
#或用mpirun运行
#mpirun  <options> ./ calc_openmp_mpi
```

设置变量OMP_NUM_THREADS，控制单进程的并发线程数

# 谢 谢